

三维数据集上分类方法对比实验报告

(Decision Trees / AdaBoost + Decision Trees / SVM)

(填写姓名 / 学号)

2026 年 4 月 8 日

摘要

在任务书规定的三维月牙数据与划分下，报告从零实现的 **Gini 决策树**、以该树为弱学习器的 **AdaBoost**，以及 `sklearn.svm.SVC` 在 **linear**、**rbf**、**poly** 三种核上的测试集表现（准确率及对 **C1** 的查准率、查全率），并从数据几何与归纳偏置角度解释何者更优及原因。

1 任务书要求

给定程序生成三维数据集，共 1000 个样本、两大类 **C0** 与 **C1**。利用该数据训练分类器，并重新生成与训练数据同分布的 500 个样本（**C0** 250、**C1** 250）作为测试集。比较 **Decision Trees**、**AdaBoost + Decision Trees** 与 **SVM** 的分类性能，并讨论对于本问题，为何某些算法表现相对更好。其中 **SVM** 至少选用三种不同的核函数（kernel functions）。

本文与同目录 Jupyter 笔记本 `make_moons_3d_classification.ipynb` 一致：标签 0 记为 **C0**，1 记为 **C1**。

2 数据集与协议

2.1 生成与划分

对每类样本数 n ，在参数 $t \in [0, 2\pi]$ 上构造三维两月牙并叠加各向同性高斯噪声。与任务书及程序一致：

- **训练集**： $2 \times 500 = 1000$ 点（**C0**、**C1** 各 500），噪声标准差 $\sigma = 0.2$ ；
- **测试集**：再次调用同一生成函数独立采样 $2 \times 250 = 500$ 点（**C0**、**C1** 各 250），与训练同分布且不参与训练；
- 使用 `numpy.random.seed(42)` 保证可复现（先采训练集再采测试集，相当于连续两次独立同分布抽样）。

2.2 评价指标

在测试集上报告**准确率**；并针对 **C1**（正类）报告**查准率** $TP/(TP+FP)$ 与**查全率** $TP/(TP+FN)$ 。

3 方法（对应任务书三项）

3.1 Decision Trees

手写基于加权基尼不纯度的二叉树（未使用 `sklearn.tree`）。节点内权重 w_i , $W = \sum_i w_i$, $W_c = \sum_{i:y_i=c} w_i$ ($c \in \{0, 1\}$ 即 **C0/C1**):

$$G = 1 - \left(\frac{W_0}{W}\right)^2 - \left(\frac{W_1}{W}\right)^2. \quad (1)$$

候选分裂最小化子节点加权基尼 $G_{\text{split}} = \frac{W_L}{W} G_L + \frac{W_R}{W} G_R$ 。fit 支持 `sample_weight`, 供 AdaBoost 使用。实验中**单棵决策树**取较大深度（如 `max_depth=8`）作为非提升基线。

3.2 AdaBoost + Decision Trees

未使用 `sklearn.ensemble`。弱学习器为上一节**手动决策树**；提升部分采用离散 AdaBoost, $y_i^\pm \in \{-1, +1\}$ (**C0** $\rightarrow -1$, **C1** $\rightarrow +1$), 加权错误率

$$\varepsilon_t = \frac{\sum_i w_i^{(t)} \mathbb{I}[h_t(x_i) \neq y_i^\pm]}{\sum_i w_i^{(t)}}. \quad (2)$$

令 $\alpha_t = \frac{1}{2} \ln \frac{1-\varepsilon_t}{\varepsilon_t}$, 权重更新为

$$w_i^{(t+1)} \propto w_i^{(t)} \exp(-\alpha_t y_i^\pm h_t(x_i)), \quad (3)$$

归一化后训练下一轮。最终 $\text{sign}(\sum_t \alpha_t h_t(x))$ 。弱学习器取**决策桩** (`max_depth=1`), 对应 **AdaBoost + Decision Trees** 的常见设置。

3.3 SVM 与三种核函数

使用 `sklearn.svm.SVC`, 满足任务书「至少三种 kernel」: **linear**、**rbf** (`gamma='scale'`)、**poly** (次数 3, `coef0=1.0`), $C = 1.0$, `random_state=42`。

4 实验结果

表 ?? 为 `seed=42` 下与笔记本一致实现得到的**测试集**指标（重新运行笔记本时以最新输出为准）。

5 讨论：为何某些算法在本问题上更好

5.1 Decision Trees

轴平行分裂用大量与坐标面对齐的台阶逼近**弯曲月牙**, 在 $\sigma = 0.2$ 噪声下易出现**过拟合**或**边界碎片化**, 故单独决策树往往中等表现, 不如能直接学习平滑非线性边界的核 SVM。

表 1: 任务书测试集 (500 点, C0/C1 各 250) 上的性能; Precision/Recall 针对 C1

方法 (与任务书对应)	准确率	查准率 (C1)	查全率 (C1)
Decision Trees (Gini, 手写)	0.8160	0.8135	0.8200
AdaBoost + Decision Trees (决策桩)	0.7300	0.7091	0.7800
SVM + linear kernel	0.6880	0.6865	0.6920
SVM + RBF kernel	0.9820	0.9801	0.9840
SVM + poly kernel	0.9800	0.9800	0.9800

(可选) 插入笔记本导出的训练/测试三维散点图, 如
`figures/moons3d_train_test.pdf`

图 1: 三维 C0/C1 分布示意; 可将笔记本图形导出至 `figures/` 后用 `\includegraphics` 插入。

5.2 AdaBoost + Decision Trees

式 (??) 使误分样本权重增大, 后续决策树 (桩) 更关注难分区域, 投票组合多个弱边界, 强于单棵浅树。但弱学习器仍是轴平行模型, 在强噪声与非线性几何下可能不稳定或仍不足, 本组超参下可低于 RBF/poly SVM。

5.3 SVM 与三种核

线性核等价于单个分离超平面, C0/C1 在三维嵌入后通常线性不可分, 故常欠拟合。RBF 与多项式核引入非线性, 更易贴合簇状弯曲结构; RBF 侧重局部相似度, 多项式核形状受次数约束, 二者常显著优于线性核, 具体排序依赖 C 、 γ 等调参。

6 结论

在任务书给定的三维月牙设定下, 非线性核 SVM (RBF、多项式) 与数据几何匹配最好, 测试指标最高; Decision Trees 次之; AdaBoost + Decision Trees 通过重加权有理论优势, 但在本实验配置下未超过最优核 SVM。后续可对树深度、提升轮数及 SVM 超参做系统搜索或交叉验证。

参考文献

- [1] Pedregosa, F. et al. Scikit-learn: Machine Learning in Python. *JMLR* 12 (2011), 2825–2830.
- [2] Freund, Y. and Schapire, R. E. A Short Introduction to Boosting. *Journal of Japanese Society for Artificial Intelligence*, 1999.