

PRML 作业四：Transformer 复现与模块消融

黄馨琰

2495657518@qq.com

2026 年 5 月 16 日

摘要

在 Multi30k 德英翻译任务上实现了 Vaswani 等提出的 Encoder-Decoder Transformer，并完成全量数据下的基线训练与两项模块消融。基线模型验证集 BLEU 最高约 18.7；去掉子层残差后，前四个 epoch 的训练损失几乎不降、BLEU 接近 0。位置编码方面，在相同的半量训练数据设定下做了 sin PE 与无 PE 的配对对照：5 个 epoch 后两组 $\mathcal{L}^{\text{tok}}$ 均明显下降，但验证 BLEU 上无 PE 组（约 12.7）略高于 sin PE 组（约 10.8），未见正弦 PE 带来稳定增益。

1 引言

作业要求复现 *Attention Is All You Need*，并通过对照实验弄清各模块是否“真的有用”。我实现了一个德 → 英的 seq2seq Transformer，主要做了两件事：全数据跑通基线；在算力允许范围内做残差（2.3）和位置编码（2.1）的消融。

第一次写位置编码部分时，我把“半数据、无位置编码”的曲线和“全数据、有位置编码”的基线画在同一张图上——事后看这是不对的：数据量减半本身就会让收敛变慢，没法单独归因到“去掉 PE”。返修后补跑了半数据 + 有位置编码（A 组）与半数据 + 无 PE（B 组），只改 PE 这一项再比（见表 5）。

2 Transformer 复现

2.1 模型

结构按论文：6 层 Encoder、6 层 Decoder；每层有自注意力（Decoder 还有交叉注意力）和两层 FFN；子层输出与输入残差相加后做 LayerNorm。注意力为

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V. \quad (1)$$

词嵌入上叠加正弦位置编码。模型宽度 512、8 头、FFN 维度 2048，dropout 0.1。

2.2 数据与训练

数据来自 Multi30k 德英句对（约 2.9 万训练句）。分词用 spacy；按词频建表；句子截断到 128 token。优化用 Adam + Noam 学习率（warmup 4000 步）；损失为带 0.1 label smoothing 的交叉熵。验证、测试用贪心解码，BLEU 分别在 300、500 句上算（不是全集，数值会偏小一些）。

2.3 基线结果

全量数据训练 15 个 epoch。验证 BLEU 在 epoch 6、8 附近最高（约 18.7）；训练到后面 loss 又涨上去、BLEU 掉下去——像是过拟合，也可能是学习率后期不太合适。写报告时我取验证 BLEU 最好的那一轮，不用最后一轮。摘要见表 1。

表 1: 全量基线（正弦位置编码 + 残差）部分 epoch 记录

Epoch i	$\mathcal{L}_i^{\text{tok}}$	valid BLEU ($\times 100$)	说明
1	5.4213	0.17	
4	2.6380	11.47	
6	2.2061	18.68	验证最优附近
8	1.9561	18.62	
15	2.0040	10.28	末轮，已变差

3 实验设置与符号

哪些一样、哪些不一样。原先写「消融与基线层数、宽度、优化器、batch size 相同」指的是模型结构和优化超参一致（见表 2）；并不是说每次实验的数据量、训练轮数、早停策略都一样。残差消融在全量 29000 句上只改「有没有 $x+$ 残差」；位置编码消融在半数据（每 epoch 随机 50% 句）上只改「有没有 sin PE」。

表 2: 各次实验配置对照（✓ = 与全量基线相同）

项目	全量基线	2.3 无残差	2.1 半数据 A/B
6 层 / $d=512$ / 8 头 / FFN 2048	✓	✓	✓
Adam + Noam (warmup 4000)	✓	✓	✓
batch size 128, label smoothing 0.1	✓	✓	✓
训练句数 / epoch	29000	29000	14500 (50%)
计划 epoch 数	15	5	5
早停	无 (跑满)	patience= 3	关闭
单变量改动	—	关残差	A: sin PE; B: 无 PE

符号表示 设第 i 个训练 epoch 结束后的平均每 token 交叉熵为 $\mathcal{L}_i^{\text{tok}}$ （即日志里的 train loss/token）。验证集 BLEU 记为 B_i （表中有时写成百分数，即 $100 \times B_i$ ）。前四个 epoch 的损失下降“斜率”定义为

$$\Delta \mathcal{L}^{\text{tok}} = \frac{\mathcal{L}_1^{\text{tok}} - \mathcal{L}_4^{\text{tok}}}{4}, \quad (2)$$

表示这 4 轮里 loss 平均每 epoch 下降多少； $\Delta \mathcal{L}^{\text{tok}}$ 越大，前期收敛越快。

半数据模式 算力不够跑全量消融时，采用半数据模式：固定随机种子，每个 epoch 只随机用 50% 的训练句（约 14500 句），共训练 5 个 epoch，不早停。位置编码对比**必须**在半数据模式下比较两条曲线：一条保留正弦 PE，一条去掉 PE；其它设置相同。全量基线只用来展示“模型能训起来”，不参与 PE 的同级对比。

4 残差消融 (2.3)

4.1 实验设置

唯一改动:关闭 Encoder/Decoder 子层里的 $x + \text{Sublayer}(x)$, 改成只做 $\text{LayerNorm}(\text{Sublayer}(x))$ 。位置编码、数据量、层数与全量基线一致 (全量 29000 句, 训练 5 epoch, 第 4 epoch 后早停)。

4.2 结果

表 3 是前 4 个 epoch 的 $\mathcal{L}^{\text{tok}}$ 和 B_4 。图 1 为同一数据的曲线。

表 3: 有残差 (全量基线) 与无残差 (全量) 前四 epoch 对比

设置	$\mathcal{L}_1^{\text{tok}}$	$\mathcal{L}_2^{\text{tok}}$	$\mathcal{L}_3^{\text{tok}}$	$\mathcal{L}_4^{\text{tok}}$	$100 \cdot B_4$	$\Delta \mathcal{L}^{\text{tok}}$
有残差	5.4213	3.6305	2.9902	2.6380	11.47	0.6958
无残差	5.6614	4.5614	4.4089	4.3282	0.0024	0.3333




图 1: 残差消融: 前 4 epoch 的训练损失与验证 BLEU

4.3 讨论

有残差时, 第一轮 $\mathcal{L}_1^{\text{tok}} \approx 5.42$, 四轮下来 $\Delta \mathcal{L}^{\text{tok}} \approx 0.70$, B_4 能到 11 左右。无残差时, 第一轮 loss 就更高 (5.66), 四轮后还在 4.33 附近晃, B_4 基本是 0——译出来的东西和乱猜差不多。第 4 epoch 后验证 BLEU 一直起不来, 触发了早停。

我自己的理解 (不一定严谨): 6 层堆在一起, 如果没有那条“直接把输入加回去”的路, 每一层都得靠训练去模仿恒等映射, 前期梯度很难传下去, 所以 loss 掉得极慢。论文里 ResNet 那套说法在这里能对上号, 但对我更有用的是表里的数: 关掉残差, 这个规模的模型前几轮等于没在学翻译。

5 位置编码消融 (2.1)

5.1 实验设置

在半数据模式下，对照 A：正弦位置编码 + 残差；对照 B：去掉位置编码（嵌入不再加 PE）+ 残差。两组都用相同的 50% 采样方式和 5 个 epoch。此前版本曾把 B 和全量基线画在一起，已作废；正文只保留 A vs B。

5.2 结果

无 PE 组（B）的逐 epoch 数据见表 4。有 PE 的对照组（A）与 B 组均在半数据模式下训满 5 个 epoch；逐 epoch 数值见表 5，配对曲线见图 2。


表 4: 半数据、无位置编码（B 组）

i	$\mathcal{L}_i^{\text{tok}}$	$100 \cdot B_i$
1	5.9176	0.03
3	3.4533	8.05
5	2.7098	12.72

表 5: 半数据位置编码对照（A: sin PE; B: 无 PE）

i	A: sin PE		B: 无 PE	
	$\mathcal{L}_i^{\text{tok}}$	$100 \cdot B_i$	$\mathcal{L}_i^{\text{tok}}$	$100 \cdot B_i$
1	5.8939	0.02	5.9176	0.03
3	3.7045	5.34	3.4533	8.05
5	2.9457	10.81	2.7098	12.72

2.1 PE ablation: matched 50% data per epoch



Both runs: experiment_mode, 50% train sentences per epoch (fixed seed). Compare sin PE vs no PE only; do not mix with full-data baseline on the same axis.

图 2: 半数据模式下，仅位置编码不同时的 loss 与 BLEU（A: sin PE, B: 无 PE）

5.3 讨论

无 PE 时模型情况：无 PE 时模型不是完全训不动，B 组 5 个 epoch 里 loss 从 5.9 降到 2.7，BLEU 也能到 12 左右。但 Decoder 还有因果 mask，源端也有序列顺序，所以“一点位置信息都没有”并不等于“一点顺序都没有”——能学到一些东西并不奇怪。

对比是否公平：PE 部分只应在表 2 里「半数据 A/B」两行之间比；若只拿 B 去和全量基线比，我会分不清是 PE 的锅还是数据变少的锅。配对结果（表 5）：第 1 epoch 两组 $\mathcal{L}_1^{\text{tok}}$ 都在 5.9 附近、 $B_1 \approx 0$ ；到第 3 epoch，B 的 $\mathcal{L}_3^{\text{tok}} = 3.45$ 、 $B_3 = 8.05$ ，已略优于 A ($\mathcal{L}_3^{\text{tok}} = 3.70$ ， $B_3 = 5.34$)；第 5 epoch 仍如此——B 的 $\mathcal{L}_5^{\text{tok}} = 2.71$ 、 $B_5 = 12.72$ ，A 为 $\mathcal{L}_5^{\text{tok}} = 2.95$ 、 $B_5 = 10.81$ 。因此在「半数据 + 5 epoch + 本实现」下，不能说正弦 PE 带来了更高的验证 BLEU；反而无 PE 组略好，可能与随机 50% 子采样、学习率日程等噪声有关，需要更长训练或多次 seed 才能下更强结论。推断阶段关掉 PE 时注意力更散（第 7 节热力图）与「训练时完全不加 PE 反而 BLEU 略高」并不矛盾：前者是同一组权重上的推理消融，后者是重新训练得到的另一套参数。

全量基线的训练曲线单独放在第 8 节，不与图 2 混画。

6 注意力热力图

图 3、图 4 用的是全量基线训练得到的权重（sin PE），在测试集句子上画 Encoder 第 5 层（最后一层）的 8 个头。左/上为推断时保留位置编码（与训练一致）；右/下为同一组权重、推断时关掉 PE（不重训）。这不是又训了一个无 PE 模型，只是看「位置表在推理阶段起什么作用」。

测试句 index 0（图 3）：开 PE 时多个头在对角附近更亮；关 PE 后色块更匀，标题里的 Attention Entropy 会变大（匹配更散）。index 7（图 4）更长，现象类似。色条固定在 $[0, 1]$ ，方便两张图比明暗。推理时必须关掉 Dropout（eval 模式），否则热力图上的斑点是噪声，不能当真。




图 3: 测试句 0: sin PE（左）与推断期关 PE（右），Encoder 层 5 多头自注意力




图 4: 测试句 7: 同上对比

说明:report/ 里还有 fig_2_1_no_pe_loss_bleu.png、fig_2_1_vs_baseline_ref_early.png 是返修前用的曲线（半数据无 PE vs 全量基线叠图）；正文已改用表 5 与图 2 的配对设计，故不再插入那两张旧图。

7 基线训练曲线与 checkpoint




图 5: 全量基线 15 epoch: $\mathcal{L}^{\text{tok}}$ 与验证 BLEU

图 5 里, epoch 12 以后训练 loss 反弹、BLEU 下滑。我后来都存 valid BLEU 最好的权重, 不用第 15 轮的。若继续训, 可能会加早停, 但作业时间里先做到“知道末轮不代表最好”即可。

8 总结

- 基线能到 valid BLEU ≈ 18.7 , 说明实现和训练管线基本可用。
- 无残差时前几轮几乎学不到翻译; 残差对深层 Transformer 不是可选项, 至少在小数据 epoch 数下是这样。
- 半数据 PE 配对 (表 5): 5 epoch 内无 PE 组 BLEU 略高于 sin PE 组, 与“PE 一定提升 BLEU”的直觉不一致; 残差消融结论仍明确。

9 附录: 复现与工程细节

9.1 仓库主要文件

- `transformer_model.py`: 模型与消融开关 (残差、位置编码、QKV 模式)。
- `train.py`: 训练、验证、写 `runs/run_< 时间戳 >/`。
- `analyze_ablation.py`: 画消融曲线、生成表格。
- `visualize_attention.py`: 注意力热力图。

9.2 训练命令

```
cd hw_4
```

```
# 全量基线
```

```
python train.py --local-repo <path>/dataset-master
```

```
# 2.3 无残差（全量，config 默认 use_residual=False 或见仓库说明）
```

```
python train.py --local-repo <path>/dataset-master
```

```
# 2.1 半数据 + 无 PE（B 组，已完成）
```

```
python train.py --local-repo <path>/dataset-master --experiment \  
    --pos-encoding none --epochs 5 --use-residual --no-early-stopping
```

```
# 2.1 半数据 + sin PE（A 组，对照，须与 B 组同 seed / 同 experiment 逻辑）
```

```
python train.py --local-repo <path>/dataset-master --experiment \  
    --pos-encoding sin --epochs 5 --use-residual --no-early-stopping
```

B 组: report/none_pe_experiment_metrics.csv (runs/run_1778835536975079123/). A 组: report/half_sin_pe_experiment_metrics.csv (runs/run_1778917710396986673/; best valid BLEU ≈ 10.81 , test ≈ 10.88).

9.3 作图命令

```
# 2.3
```

```
python analyze_ablation.py --out-fig report/fig_ablation_2_3_ep1_4.png
```

```
# 2.1 配对对照（A、B 均半数据）
```

```
python analyze_ablation.py \  
    --half-sin-pe-csv report/half_sin_pe_experiment_metrics.csv \  
    --none-pe-csv report/none_pe_experiment_metrics.csv \  
    --out-fig-2-1-paired report/fig_2_1_pe_paired.png --early-epochs 5
```

```
# 全量基线监控
```

```
python analyze_ablation.py --out-fig-monitor report/fig_baseline_train_monitor.png
```

```
# 注意力
```

```
python visualize_attention.py --checkpoint runs/<run>/best_model.pt \  
    --run-dir runs/<run> --test-index 0 --layer 5 --attn-colorbar fixed01
```

9.4 编译

在 hw_4/ 下执行 xelatex hw_4.tex。